


Avances de equipo técnico.

junio, 2026




Estructura de la presentación.

- 1. Contexto y línea base forestal**
- 2. Auditoría de la base de datos (metodología, criterios de scoring, resultados, hallazgos)**
- 3. Armonización temática (clases semánticas y homologación)**
- 4. Normalización y disponibilidad de datos**
- 5. Producto actual y próximos pasos**

1. Contexto y línea base forestal

Etapa 1: Mapa Línea base forestal regional.



2. Auditoría de la base de datos

Avance metodológico y productos generados

Marco metodológico utilizado para estructurar la auditoría

Metodología CRISP-DM: marco de referencia para las fases y tareas del proceso de datos

1. Business Understanding

- Business objectives
- Situation assessment
- Data mining goals
- Project plan

2. Data Understanding

- Initial data collection
- Data description
- Data exploration
- Data quality verification

3. Data Preparation

- Data selection
- Data cleaning
- Data construction
- Data integration
- Data formatting

4. Modeling

- Modeling technique selection
- Test design
- Model building
- Model assessment

5. Evaluation

- Results evaluation
- Process review
- Next steps determination

6. Deployment

- Deployment plan
- Monitoring & maintenance
- Final report
- Project review

Fuente: Pete Chapman et al. (1999), CRISP-DM 1.0.

Contexto: flujo de trabajo



La base de datos proviene de una consultoría previa.



Fue enfoque en recompilar las fuentes originales: el trabajo actual debe concentrarse en auditar, normalizar y hacer trazable la información existente.




El flujo propuesto ordena la base, identifica conflictos y prepara una llave de clasificación operativa para el mapeo forestal.

Enfoque: aplicar técnicas de Ciencia de Datos para su recopilación, preparación, análisis, visualización y gestión, consolidando una base de datos estandarizada para el modelado.

Objetivo: pasar de registros heredados a una base depurada, normalizada y apta para análisis

Pipeline ejecutado como arquitectura de datos


Actividad 1



Sistema de puntuación multicriterio utilizado para clasificar la ‘calidad’ de los datos

Criterio	Campo score	Peso	Qué evalúa	Cómo se obtiene	Efecto en el resultado
Temporal	score_temporal	20%	Cercanía del grupo XY al año objetivo 2020	A cada registro se le asigna un puntaje según su año: 2020=100; 2019/2021=90; 2018/2022=85. Si un grupo XY tiene varios registros, se conserva el mejor puntaje temporal del grupo.	Favorece grupos XY con evidencia cercana a 2020.
Espacial	score_espacial	20%	Limpieza del grupo XY dentro de la ventana 2018-2022	Usa estado_xy_subset: XY único=100; multitemporal estable=90; coincidencia entre fuentes con misma clase=85; redundancia misma fuente/misma clase=70; conflicto temático=0.	Penaliza coordenadas con duplicidad problemática o conflicto entre clases.
Temático	score_tematico	20%	Consistencia y claridad de la clase asignada	Combina cuatro componentes: consistencia de clase 40%, viabilidad país-clase 30%, claridad semántica 20% y nivel de leyenda 10%. Penaliza conflictos entre niveles, clases residuales como “otras”, baja representación país-clase y leyendas poco específicas.	Evita que clases ambiguas, residuales o poco respaldadas entren como datos fuertes de entrenamiento.
Espectral	score_espectral	15%	Coherencia entre la clase del punto y la señal Sentinel-2	Usa la auditoría espectral del Módulo 09 agregada por xy_group_id. Parte de 100 y resta penalizaciones por alertas altas, alertas medias, baja disponibilidad, ausencia de datos y necesidad de revisión espectral.	Reduce la aptitud de puntos cuya señal espectral es dudosa o insuficiente. Alertas altas también pueden activar topes.
Confiabilidad	score_confiabilidad	10%	Confianza conjunta en las variables auxiliares NDVI, cobertura y altura	La base original trae conf_ndvi, conf_cobertura y conf_altura. conf_integrada corresponde al promedio de esas tres confianzas. Luego el scoring normaliza conf_integrada a escala 0-100 y promedia por xy_group_id.	Favorece grupos XY cuyos registros tienen variables auxiliares más confiables. No mide fuente ni Sentinel-2; esos son criterios separados.
Representatividad	score_representatividad	10%	Suficiencia de datos por país y clase	Cuenta registros por combinación país + clase nivel 1. Si hay suficiente soporte=100; moderado=85; bajo=65; crítico=40; sin matriz=70.	Penaliza combinaciones país-clase con pocos datos, aunque el punto individual parezca bueno.
Fuente	score_fuente	5%	Calidad documental y trazabilidad de la fuente	Usa source_catalog.csv. Calcula un score por fuente con directitud 50%, trazabilidad 25% y consistencia temporal de metadatos 25%. Después, por cada XY, promedia las fuentes únicas presentes.	Favorece fuentes más directas, trazables y temporalmente consistentes. Una fuente repetida en el mismo XY cuenta una sola vez.


Resultados: Distribución temporal 2000-2022



Datos 2000-2022


Resultados: distribución registros

Magnitud de la duplicidad espacial



Resultados: ventana temporal


Pertinencia temporal para línea base 2020



No debemos contemplar información tan antigua


Resultados: ventana temporal vs datos

Cobertura ampliada: 2020 vs 2018-2022




Resultados: análisis espectral

Flujo usado para la auditoría espectral



Sentinel-2 aporta evidencia espectral-temporal complementaria.

Resultados: alertas espectrales



Resultados: qué deja lo realizado anteriormente

Se transforma registros heterogéneos en grupos XY auditados, scoreados y normalizados:

Ejecución de pipeline de análisis de datos

- 1,195,911 registros evaluados en la ventana 2018-2022
- 1,111,850 grupos XY consolidados
- Scoring multicriterio aplicado a 22 fuentes y 8 países

Hallazgos principales

- Duplicidad espacial: múltiples registros pueden corresponder a una misma ubicación XY.
- Conflictos temáticos: un mismo XY puede tener más de una clase asociada.
- Clases con pocos puntos: existen categorías con baja representatividad para entrenamiento o validación.
- Países desbalanceados: la disponibilidad de puntos no es homogénea entre países.

Implicación: antes del mapeo se requiere depurar por XY, país, clase y fuente, y documentar las decisiones de exclusión o reclasificación.

Ejemplo conflictos temáticos

The screenshot shows the QGIS interface with a map of a rural area. The 'Capas' (Layers) panel on the left lists the following layers from top to bottom:

- ☒ a2_1_xy_point — xy_point
- ☐ a2_1_xy_point — clase_origen_nivel_2
- ☐ a2_1_xy_point — clase_origen_nivel_1
- ☐ a2_1_xy_point — clase_origen_nivel_0
- ☒ Google Satellite


The 'Resultados de la identificación' (Identification Results) panel on the right shows the following data for the selected layer:

Objeto espacial	Valor
a2_1_xy_point — xy_point	
Titulo	XY_000000685383
(Derivado)	
(Acciones)	
fid	655502
xy_group_id	XY_000000685383
lon	-88.5535
lat	16.5223
pais_grupo	Belice
id_0	30
id_1	31
id_2	312
nivel_0	Tierras de Cultivo y Pastos
nivel_1	Cultivos intensivos No-Arbóreos
nivel_2	Bananeras


The status bar at the bottom indicates the current mode is 'Capa actual' (Current Layer) and the view is 'Arbol' (Tree). The status bar also shows the coordinates (16.53077°, -88.55587°), scale (1:6465), zoom (100%), rotation (0.0°), and projection (EPSG:4326).

Se presentan discrepancias entre los diferentes niveles de clasificación

Densidad registros



Dominancia clases



3. Armonización temática (clases semánticas y homologación)

Definición de clases semánticas

- Propuesta de llave de clasificación acordada con **partes interesadas técnicas** (GIZ-UVG-UNA).
- La clasificación debe **equilibrar una leyenda ideal con una leyenda factible para el mapeo forestal**:
 - Llave armonizada y equivalencias entre clases actuales y clases propuestas
 - Unidad Mínima de Mapeo: referencia FAO de 0,5 ha.

Estas decisiones tienen implicaciones directas sobre la aptitud de los puntos y la leyenda final del producto de clasificación

Definición de clases semánticas

Código N0	Clase general	Código N1	Clase específica
1	Bosques / Tierras forestales	11	Bosques latifoliados y mixtos
1		12	Bosques de coníferas
1		13	Bosques de mangle
1		14	Bosques secos
1		15	Plantaciones forestales
2	No Bosques	21	Cultivos arbóreos
2		22	Zonas agrícolas no arbóreas
2		23	Construido
2		24	Cuerpos de agua
2		25	Otras tierras

Dos niveles de clasificación

**Factibles desde los datos disponibles
y a conseguir, y desde la la
separatibilidad espectral**

Homologación

- Registros con homologación final: 1,111,850
- Registros resueltos por regla general: 1,027,214
- Registros resueltos por excepción desde nivel 2: 84,636
- La salida final puede unirse 1:1 por xy_group_id.

id_0_prop	nivel_0_prop	id_1_prop	nivel_1_prop
1	Bosques/Tierras forestales	11	Bosques latifoliados y mixtos
1	Bosques/Tierras forestales	12	Bosques de coníferas
1	Bosques/Tierras forestales	13	Bosques de mangle
1	Bosques/Tierras forestales	14	Bosques secos
1	Bosques/Tierras forestales	15	Plantaciones forestales
2	No Bosques	21	Cultivos arbóreos
2	No Bosques	22	Zonas agrícolas no arbóreas
2	No Bosques	23	Construido
2	No Bosques	24	Cuerpos de agua
2	No Bosques	25	Otras tierras

4. Normalización y disponibilidad de datos

Normalización de la base de datos

Base de datos normalizada.


Los labels de clase quedan separados de las tablas de puntos para mantener el modelo en 3NF

xy_point		
PK	xy_group_id	VARCHAR(80) UNIQUE NOT NULL
	lon	FLOAT
	lat	FLOAT
	pais_grupo	VARCHAR(80)
FK	id_0	INT
FK	id_1	INT
FK	id_2	INT
	geom	POINT


1. xy_point conserva la geometría y llaves principales.
2. xy_core resume atributos base del grupo XY.
3. xy_temporal guarda información de años y ventana.
4. xy_clase_resumen guarda clases dominantes y diversidad temática.
5. xy_spectral guarda auditoría Sentinel-2.
6. xy_score guarda resultados del scoring.
7. xy_conflicto y xy_accion documentan revisión y uso recomendado.

Resultados de homologación por clase

Nivel 1 homologado: registros regionales por clase



Disponibilidad de los datos y procesos



- Repositorio de GitHub.
- Organización pensada en la normalización y posibilidad de ejecución por terceros.
- Versionado y trazado por procesamiento.
- Documentación de cada actividad y resultado.

5. Producto actual y próximos pasos

Producto actual

- Diagnóstico técnico regional de datos y vacíos de información
- Marco técnico de manejo y armonización del dato, con propuesta regional de clases y reglas de correspondencia

Próximos pasos

- Propuesta de llenado de vacíos (Nuevas fuentes de datos, auditorias, levantamiento de datos, etc).
- Consolidación de equipo de fotointerpretes regional con actores interesados.
- Generar la versión de la base apta para entrenamiento, validación y mapeo.

Muchas gracias