


Avances de equipo técnico.

julio, 2026



Estructura de la presentación.

1. Principios de trabajo
2. Contexto y línea base forestal
3. Auditoria de la base de datos pre-existente
4. Armonización temática (clases semánticas y homologación)
5. Normalización y disponibilidad de datos
6. Exploración: Modelado de áreas piloto
7. Conclusiones y desafíos
8. Acceso a los resultados y datos generados

1. Principios de Trabajo: Ciencia de datos

Calidad de los datos: auditoría, depuración, normalización y control de consistencia antes del modelado.



Trazabilidad: documentación de las fuentes, transformaciones, exclusiones y productos generados.



Reproducibilidad: procesos estructurados en código, configuraciones y salidas verificables.




Rigor metodológico: separación espacial de los datos y uso de métricas comparables entre modelos.



Aplicabilidad: desarrollo de procedimientos replicables para incorporar nuevos datos y ampliar el análisis regional.

2. Contexto y línea base forestal

Flujograma: Mapa Línea base forestal regional.



3. Auditoría de la base de datos

¿Qué entendemos por auditoria?

Se entiende como una evaluación sistemática de la calidad, consistencia y trazabilidad de la base de datos antes de ser usada en el proceso de modelado

Su finalidad es obtener una base depurada, documentada y apta para procesos posteriores

Contexto: flujo de trabajo



La base de datos proviene de una consultoría previa.



Fue enfoque en recompilar las fuentes originales: el trabajo actual debe concentrarse en auditar, normalizar y hacer trazable la información existente.



El flujo propuesto ordena la base, identifica conflictos y prepara una llave de clasificación operativa para el mapeo forestal.

Objetivo: pasar de registros heredados a una base depurada, normalizada y apta para análisis

Marco metodológico utilizado para estructurar la auditoría

Metodología CRISP-DM: marco de referencia para las fases y tareas del proceso de datos

1. Business Understanding

- Business objectives
- Situation assessment
- Data mining goals
- Project plan

2. Data Understanding

- Initial data collection
- Data description
- Data exploration
- Data quality verification

3. Data Preparation

- Data selection
- Data cleaning
- Data construction
- Data integration
- Data formatting

4. Modeling

- Modeling technique selection
- Test design
- Model building
- Model assessment

5. Evaluation

- Results evaluation
- Process review
- Next steps determination

6. Deployment

- Deployment plan
- Monitoring & maintenance
- Final report
- Project review


Fuente: Pete Chapman et al. (1999), CRISP-DM 1.0.

Pipeline de auditorías

Pipeline ejecutado como arquitectura de datos


Actividad 1

00 · Gobierno del dato / RAW




Zona cruda preservada
sin limpieza destructiva


01-05C · Auditorías base




06-09 · Auditorías Espectrales: Sentinel-2



10 · Scoring multicriterio



11 · Vacíos y transición




Hallazgos principales


- Duplicidad espacial: múltiples registros pueden corresponder a una misma ubicación XY.
- Conflictos temáticos: un mismo XY puede tener más de una clase asociada.
- Clases con pocos puntos: existen categorías con baja representatividad para entrenamiento o validación.
- Países desbalanceados: la disponibilidad de puntos no es homogénea entre países.

Implicación: antes del mapeo se requiere depurar por XY, país, clase y fuente, y documentar las decisiones de exclusión o reclasificación.

Densidad de registros



Dominancia de clases



4. Armonización temática (clases semánticas y homologación)

Definición de clases semánticas

- Propuesta de llave de clasificación discutida con **partes interesadas técnicas**.
- La clasificación debe **equilibrar una leyenda ideal con una leyenda factible para el mapeo forestal**:
 - Llave armonizada y equivalencias entre clases actuales y clases propuestas
 - Unidad Mínima de Mapeo: referencia FAO de 0,5 ha

Estas decisiones tienen implicaciones directas sobre la aptitud de los puntos y la leyenda final del producto de clasificación

Definición de clases semánticas

Código N0	Clase general	Código N1	Clase específica
1	Bosques / Tierras forestales	11	Bosques latifoliados y mixtos
1		12	Bosques de coníferas
1		13	Bosques de mangle
1		14	Bosques secos
1		15	Plantaciones forestales
2	No Bosques	21	Cultivos arbóreos
2		22	Zonas agrícolas no arbóreas
2		23	Construido
2		24	Cuerpos de agua
2		25	Otras tierras

Dos niveles de clasificación

Factibles desde los datos disponibles y a conseguir, y desde la separabilidad espectral

5. Normalización y disponibilidad de datos

Qué implica la normalización y la base de datos

- Integrar los registros en una estructura común y relacionada
- Homologar clases, formatos e identificadores sin perder los datos originales
- Vincular cada punto con su ubicación, fuente y clasificación
- Facilitar consultas, auditorías, actualizaciones y modelado

Qué lo hace diferente de lo usual: no es una tabla consolidada sino una base estructurada, trazable y preparada con la capacidad de incorporar nuevos datos y seguir el flujo de modelado.

Normalización de la base de datos

Base de datos normalizada.


Los labels de clase quedan separados de las tablas de puntos para mantener el modelo en 3NF

Actividad 2.1 — Modelo conceptual de ordenamiento de la salida de Actividad 1

Criterio: no se inventan atributos analíticos. Los TT campos originales se redistribuyen por tema y todos los joins se hacen mediante xy_group_id.

Campos nuevos	
campos_originales	documentación
campos_normalizados	documentación

Criterio: no se inventan atributos analíticos; los campos originales se redistribuyen por tema y los joins se hacen mediante xy_group_id




Prioridad de asignación: id_2 (excepción) → id_1_propuesta; si no existe excepción, id_1 (regla general) → id_1_propuesta.

Resultados de homologación por clase


Balance país por nivel 0

% dentro de cada país; etiqueta derecha = nXY



Nivel 1 homologado regional

Cantidad de grupos XY únicos por clase



Resultados de homologación por clase

Vacíos y alertas país x clase


Estado por país y clase original nivel 1. Los umbrales indican cobertura mínima operativa, no aptitud final para modelado.

	Otras	Otras tierras	Urbano	Bosque de coníferas	Manglares	Cuerpos de Agua	Otros arbóreo en tierras no agrícola	Humedales	Cultivos Arbóreos	Bosque latifoliado y mixto	Cultivos intensivos No-Arbóreos	Cultivos extensivos, Pastizales y
	91	12	11	42	43	21	44	22	32	41	31	33
Nicaragua	0	0	0	0	0	n	0	n	n	0	0	n
México	0	0	n	n	n	0	n	n	0		n	
Guatemala	0	n	n	n	n	n	n	n		s		
Panamá	n	n	n	0	n	n	n	n	n			
Costa Rica	s	n	s	0	0	n						
Belice	0	n	s						0			
El Salvador	n	s						0				
Honduras	0	n					n					

■ Sin puntos
 ■ Baja cantidad
 ■ Score bajo
 ■ Cumple umbral operativo

Cumple umbral operativo = $nXY \geq 200$ y score medio ≥ 80 . No implica balance espacial, independencia entre fuentes ni suficiencia para modelado sin estratificación.

Protocolo para el llenado de vacíos de información




Protocolo para el llenado de vacíos de información


- El llenado de vacíos es la piedra angular para conseguir una base de datos apta para modelado.
- La estrategia de llenado de vacíos sigue todos los procesos de auditoria de datos.
- **La participación activa de los distintos socios es clave para completar con esta etapa.**

6. Exploración: Modelado de áreas piloto

Estrategia de partición y validación espacial







Distribución y manejo de zonas piloto en cuadrantes




El uso y selección del área de los cuadrantes se basó en un proceso riguroso basado en: Stock, A. (2025).

Modelos aplicados



- Notas:**
- 1. Los cuatro modelos parten de la misma matriz y la misma partición espacial
 - 2. Cada uno conserva su preprocesamiento específico
 - 3. Entrada y evaluación compartidas.

Flujo aplicado y algoritmos usados




Métricas de comparación de modelado

Cosas a considerar en un proceso de modelado:

1. Se prueban diferentes algoritmos porque no todos aprenden igual (predicen), no responden igual a diferencias en balance de clases, la complejidad de las relaciones entre co-variables, manejo de la **auto-correlación espacial**.

2. Los comparamos porque un modelo puede sobresalir en una métrica o clase y presentar limitaciones en otra. En estos resultados, ningún algoritmo domina simultáneamente todos los criterios.





7. Conclusiones y desafíos

Desafíos observados


- **Clases poco representadas:** plantaciones, otras tierras y coníferas requieren más observaciones y mayor cobertura geográfica. El protocolo de la Actividad 3 permite orientar el llenado de estos vacíos.
- **Predictores heterogéneos:** aunque superaron los controles generales, algunos presentan limitaciones específicas; por ejemplo, máscaras de agua en Sentinel-1 que generaron confusión.
- **Restricciones operativas:** la escala regional demanda gran capacidad de descarga, almacenamiento y procesamiento, evidenciando la necesidad de infraestructura de alto rendimiento.
- **Alcance piloto:** las cinco zonas no representan toda la diversidad regional. La revisión cartográfica fue cualitativa; una aplicación regional requerirá más datos y una validación cartográfica independiente.

Conclusiones

- Se desarrolló un pipeline reproducible y trazable que generó una base de calidad apta para el modelado geoespacial
- Se estableció un protocolo replicable para tratar vacíos e incorporar nuevas fuentes bajo criterios comunes y verificables
- La separación espacial por cuadrantes permitió comparar los modelos en condiciones equivalentes
- **Random Forest** presentó la mayor coherencia cartográfica en las cinco zonas piloto, aunque los demás modelos fueron competitivos en distintas métricas
- La aplicación regional requerirá fortalecer las clases poco representadas, mejorar los predictores y realizar una validación cartográfica independiente
- La validación del modelo evaluó su transferencia a cuadrantes no utilizados en el entrenamiento, pero no representa una estimación definitiva de la exactitud cartográfica regional

8. Acceso a los resultados y datos generados

Disponibilidad de los datos y procesos



- Repositorio de GitHub.
- Organización pensada en la normalización y posibilidad de ejecución por terceros.
- Versionado y trazado por procesamiento.
- Documentación de cada actividad y resultado.

Muchas gracias