


Avances de equipo técnico.

julio, 2026



Estructura de la presentación.

1. Principios de trabajo
2. Contexto y línea base forestal
3. Auditoria de la base de datos pre-existente
4. Armonización temática (clases semánticas y homologación)
5. Normalización y disponibilidad de datos
6. Exploración: Modelado de áreas piloto
7. Conclusiones y desafíos
8. Acceso a los resultados y datos generados

1. Principios de Trabajo: Ciencia de datos

Calidad de los datos: auditoría, depuración, normalización y control de consistencia antes del modelado.



Trazabilidad: documentación de las fuentes, transformaciones, exclusiones y productos generados.



Reproducibilidad: procesos estructurados en código, configuraciones y salidas verificables.




Rigor metodológico: separación espacial de los datos y uso de métricas comparables entre modelos.



Aplicabilidad: desarrollo de procedimientos replicables para incorporar nuevos datos y ampliar el análisis regional.

2. Contexto y línea base forestal

Flujograma: Mapa Línea base forestal regional.



3. Auditoría de la base de datos

¿Qué entendemos por auditoria?

Se entiende como una evaluación sistemática de la calidad, consistencia y trazabilidad de la base de datos antes de ser usada en el proceso de modelado

Su finalidad es obtener una base depurada, documentada y apta para procesos posteriores

Contexto: flujo de trabajo



La base de datos proviene de una consultoría previa.



Fue enfoque en recompilar las fuentes originales: el trabajo actual debe concentrarse en auditar, normalizar y hacer trazable la información existente.



El flujo propuesto ordena la base, identifica conflictos y prepara una llave de clasificación operativa para el mapeo forestal.

Objetivo: pasar de registros heredados a una base depurada, normalizada y apta para análisis

Marco metodológico utilizado para estructurar la auditoría

Metodología CRISP-DM: marco de referencia para las fases y tareas del proceso de datos

1. Business Understanding

- Business objectives
- Situation assessment
- Data mining goals
- Project plan

2. Data Understanding

- Initial data collection
- Data description
- Data exploration
- Data quality verification

3. Data Preparation

- Data selection
- Data cleaning
- Data construction
- Data integration
- Data formatting

4. Modeling

- Modeling technique selection
- Test design
- Model building
- Model assessment

5. Evaluation

- Results evaluation
- Process review
- Next steps determination

6. Deployment

- Deployment plan
- Monitoring & maintenance
- Final report
- Project review

Fuente: Pete Chapman et al. (1999), CRISP-DM 1.0.

Pipeline de auditorías

Pipeline ejecutado como arquitectura de datos

Actividad 1

00 · Gobierno del dato / RAW

00 Estructura reproducible
config data src outputs docs logs

GeoPackage original
Puntos_control_mesoamerica

2.881.123 registros
41 campos · Point
EPSG-4326

No alterar
Auditor primerio
Documentar decisiones

Zona cruda preservada
sin limpieza destructiva

01-05C · Auditorías base

01 Perfil GPKG

02 Estructural

03 Espacial

03B Grupos XY

SQLite
03B multiregistros XY

04 Temporal

05 Temática

SQLite
05 auditoria temática

05B Ventana operativa

05C Conflictos

1.283.836 grupos XY
758.797 repetidos
55.45% reducción potencial

2020 exacto: 225.478
2018-2022: 1.195.911

5 · 12 · 40 clases
0 inconsistencias jerárquicas

2.779 grupos conflictivos
2.884 prioridad a 75

Particionar por
xy_group_id

Conflictos altos
no van directo a
entrenamiento

06-09 · Auditorías Espectrales: Sentinel-2

06 Input
2018-2022 LongLatIdNo

07 Script
documentado

Exportación
S2 SR + s2cloudless

08 Join espectral

GeoPackage procesado
S2 + registros originales

09 Auditoria espectral

GeoPackage procesado
alertas espectrales

42 batches
42 CSV · 6.5 GB

1.185.946 extract_id
0 faltantes · 0 extras

508.171 priorizados
42.492% con alerta

Sentinel-2 = calidad
no validación definitiva

10 · Scoring multicriterio

config
scoring_aplitud.yaml

10 Aptitud por
xy_group_id

Pesos
T 0.20 · E 0.20 · Tema 0.20
S2 0.15 · Conf 0.10
Reg 0.10 · Fuente 0.05

1.111.850 grupos XY
52 fuentes · 9 países
100% cobertura espectral XY

GeoPackage final
scoring_aplitud

Clasificación funcional
Entrenamiento · Validación · Prueba
Apoyo · Referencia · Máscara

Entrenamiento: 853.806 XY
Validación: 194.770 XY
Prueba: 53 XY
Máscaras: 628 XY

11 · Vacíos y transición

Diagnóstico país-clase
vacíos · bajo score · ausencias

Documentación A1
reportes · tablas · figuras

Actividad 2
normalización conceptual
lógica y física

Modelo normalizado
xy_point + 7 tablas XY
catálogos de origen 3NF

outputs/
reports · tables · figures

Salida clasificada según uso
no solo según disponibilidad

Esta sección implica que tenemos una
propuesta de homologación basada en
conversaciones con especialistas de
las universidades que forman parte del
proyecto

Homologación de clases
id_0 → id_0_propuesta
id_1 → id_1_propuesta
excepción: id_2 → id_1_propuesta
xy_homologacion_final para QGIS


1.111.850 filas
xy_core · temporal · clase
spectral · score · conflicto · acción

Hallazgos principales


- Duplicidad espacial: múltiples registros pueden corresponder a una misma ubicación XY.
- Conflictos temáticos: un mismo XY puede tener más de una clase asociada.
- Clases con pocos puntos: existen categorías con baja representatividad para entrenamiento o validación.
- Países desbalanceados: la disponibilidad de puntos no es homogénea entre países.

Implicación: antes del mapeo se requiere depurar por XY, país, clase y fuente, y documentar las decisiones de exclusión o reclasificación.

Densidad de registros



Dominancia de clases



4. Armonización temática (clases semánticas y homologación)

Definición de clases semánticas

- Propuesta de llave de clasificación discutida con **partes interesadas técnicas** (GIZ-UVG-UNA).
- La clasificación debe **equilibrar una leyenda ideal con una leyenda factible para el mapeo forestal**:
 - Llave armonizada y equivalencias entre clases actuales y clases propuestas
 - Unidad Mínima de Mapeo: referencia FAO de 0,5 ha

Estas decisiones tienen implicaciones directas sobre la aptitud de los puntos y la leyenda final del producto de clasificación

Definición de clases semánticas

Código N0	Clase general	Código N1	Clase específica
1	Bosques / Tierras forestales	11	Bosques latifoliados y mixtos
1		12	Bosques de coníferas
1		13	Bosques de mangle
1		14	Bosques secos
1		15	Plantaciones forestales
2	No Bosques	21	Cultivos arbóreos
2		22	Zonas agrícolas no arbóreas
2		23	Construido
2		24	Cuerpos de agua
2		25	Otras tierras

Dos niveles de clasificación

Factibles desde los datos disponibles y a conseguir, y desde la separabilidad espectral

5. Normalización y disponibilidad de datos


Qué implica la normalización y la base de datos

- Integrar los registros en una estructura común y relacionada
- Homologar clases, formatos e identificadores sin perder los datos originales
- Vincular cada punto con su ubicación, fuente y clasificación
- Facilitar consultas, auditorías, actualizaciones y modelado


Qué lo hace diferente de lo usual: no es una tabla consolidada sino una base estructurada, trazable y preparada con la capacidad de incorporar nuevos datos y seguir el flujo de modelado.

Resultados de homologación por clase

Nivel 1 homologado: registros regionales por clase



Protocolo para el llenado de vacíos de información



Protocolo para el llenado de vacíos de información

- El llenado de vacíos es la piedra angular para conseguir una base de datos apta para modelado.
- La estrategia de llenado de vacíos sigue todos los procesos de auditoria de datos.
- **La participación activa de los distintos socios es clave para completar con esta etapa.**

6. Exploración: Modelado de áreas piloto

Exploración: Modelado de áreas piloto

¿Qué es modelar?


Aprender del territorio conocido para estimar lo que ocurre donde no tenemos observaciones.

¿Qué implica?


Seleccionar buenos ejemplos → integrar variables → entrenar algoritmos → evaluar resultados → generar mapas

¿Por qué es importante hacerlo bien?


Porque un modelo **puede** parecer muy bueno sin ser realmente confiable. Cuando no se aplican buenas prácticas, **las métricas pueden inflarse**, la incertidumbre ocultarse y el modelo comunicar una certeza mayor que la que realmente existe.



Flujo aplicado y algoritmos usados



Distribución y manejo de zonas piloto en cuadrantes




El uso y selección del área de los cuadrantes se basó en un proceso riguroso basado en: Stock, A. (2025).

Métricas de comparación de modelado

Cosas a considerar en un proceso de modelado:

1. Se prueban diferentes algoritmos porque no todos aprenden igual (predicen), no responden igual a diferencias en balance de clases, la complejidad de las relaciones entre co-variables, manejo de la **auto-correlación espacial**.

2. Los comparamos porque un modelo puede sobresalir en una métrica o clase y presentar limitaciones en otra. En estos resultados, ningún algoritmo domina simultáneamente todos los criterios.





7. Conclusiones y desafíos

Desafíos observados


- **Clases poco representadas:** plantaciones, otras tierras y coníferas requieren más observaciones y mayor cobertura geográfica. El protocolo de la Actividad 3 permite orientar el llenado de estos vacíos.
- **Predictores heterogéneos:** aunque superaron los controles generales, algunos presentan limitaciones específicas; por ejemplo, máscaras de agua en Sentinel-1 que generaron confusión.
- **Restricciones operativas:** la escala regional demanda gran capacidad de descarga, almacenamiento y procesamiento, evidenciando la necesidad de infraestructura de alto rendimiento.
- **Alcance piloto:** las cinco zonas no representan toda la diversidad regional. La revisión cartográfica fue cualitativa; una aplicación regional requerirá más datos y una validación cartográfica independiente.

Conclusiones

- Se desarrolló un pipeline reproducible y trazable que generó una base de calidad apta para el modelado geoespacial
- Se estableció un protocolo replicable para tratar vacíos e incorporar nuevas fuentes bajo criterios comunes y verificables
- La separación espacial por cuadrantes permitió comparar los modelos en condiciones equivalentes
- **Random Forest** presentó la mayor coherencia cartográfica en las cinco zonas piloto, aunque los demás modelos fueron competitivos en distintas métricas
- La aplicación regional requerirá fortalecer las clases poco representadas, mejorar los predictores y realizar una validación cartográfica independiente
- La validación del modelo evaluó su transferencia a cuadrantes no utilizados en el entrenamiento, pero no representa una estimación definitiva de la exactitud cartográfica regional

8. Acceso a los resultados y datos generados

Disponibilidad de los datos y procesos



- Repositorio de GitHub.
- Organización pensada en la normalización y posibilidad de ejecución por terceros.
- Versionado y trazado por procesamiento.
- Documentación de cada actividad y resultado.

Muchas gracias

